Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №4

За шестой семестр

По дисциплине: «Модели решения задач в интеллектуальных системах»

Тема: «Классификация линейно разделимых образов однослойным персептроном для логических функций n переменных»

Выполнил:
Студент 3 курса
Группы ИИ-26(1)
Рулько М.А.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: Реализовать нейронную сеть (однослойный персептрон) для решения задач синтеза логических функций от n входов. Сравнить эффективность обучения при различных начальных условиях и параметрах шага.

Задачи лабораторной работы:

1. Сгенерировать полную таблицу истинности для заданной логической функции (2n наборов). На выходе функции должны использоваться значения 0 и 1.
2. **Реализовать алгоритм обучения:**
   - Разделить выборку на обучающую (часть данных) и тестовую (оставшиеся наборы) для проверки обобщающей способности.
   - В качестве функции активации использовать сигмоиду
   - Провести **два эксперимента** по обучению:
     А. С фиксированным шагом обучения
     Б. С адаптивным шагом
   - Выход сети интерпретировать как вероятность принадлежности к классу «1».
   - Обучение проводить до минимизации суммарной ошибки на обучающей выборке.
3. **Провести анализ сходимости:**
   - Построить графики зависимости суммарной ошибки от номера эпохи для обучающей и тестовой выборок.
   - Оценить обобщающую способность: корректно ли сеть предсказывает значения на тех наборах из таблицы истинности, которые она не видела при обучении.
   - Зафиксировать количество эпох, необходимых для настройки весов при разных значениях
4. Вывести итоговые значения весовых коэффициентов и порога.
5. **Реализовать режим функционирования:**
   - Программа должна принимать на вход вектор из n чисел (0 или 1).
   - Сеть должна мгновенно выдавать результат (вероятность и округленный класс).

Perceptron.ts:

```
export type TrainResult =
{

  trainHistory: number[];
  testHistory: number[];
  weights: number[];
  threshold: number;
  epochs: number;

};

 function dot(a: number[], b: number[]): number
 {
  return a.reduce((s, v, i) => s + v * b[i], 0);
 }
//функция активации
 function sigmoid(x: number): number
 {
```

```
    return 1 / (1 + Math.exp(-x));
  }

  function insertBias(X: number[][]): number[][]
  {
    return X.map(row => [-1, ...row]);
  }
//среднеквадратичная ошибка
  function mse(y: number[], target: number[]): number
  {
    return y.reduce((s, v, i) => s + (v - target[i]) ** 2, 0) / y.length;
  }

  function predict(X: number[][], w: number[]): number[]
  {
    return X.map(row => sigmoid(dot(row, w)));
  }

function delta(
  X: number[][],
  y: number[],
  target: number[],
  w: number[],
  lr: number
): number[] {
  const grad = new Array(w.length).fill(0);
  for (let i = 0; i < y.length; i++) {
    const err = y[i] - target[i];
//производная сигмоиды
    const der = y[i] * (1 - y[i]);
    for (let j = 0; j < w.length; j++) {
      grad[j] += err * der * X[i][j];
    }
  }
  return w.map((wj, j) => wj - lr * (grad[j] / y.length));
}

function adaptiveLR(X: number[][]): number {
  const sumSq = X.reduce((s, row) => s + row.reduce((rs, v) => rs + v * v, 0), 0);
  return 1 / (sumSq / X.length);
}

export function generateData(N: number): { X: number[][]; Y: number[] } {
  const total = 1 << N;
  const X: number[][] = [];
  const Y: number[] = [];
  const inverseMask = [1, 0, 0, 0, 0, 0, 0, 0, 0].slice(0, N);

  for (let i = 0; i < total; i++) {
    const row: number[] = [];
    for (let b = N - 1; b >= 0; b--) {
```

```
      row.push((i >> b) & 1);
    }
    X.push(row);

    const modified = row.map((v, j) => (inverseMask[j] === 1 ? 1 - v : v));
    const target = modified.reduce((acc, v) => acc & v, 1);
    Y.push(target);
  }

  return { X, Y };
}

export function splitData(
  X: number[][],
  Y: number[],
  trainRatio = 0.9
): { XTrain: number[][]; YTrain: number[]; XTest: number[][]; YTest: number[] } {
  const onesIdx = Y.map((v, i) => (v === 1 ? i : -1)).filter(i => i >= 0);
  const zerosIdx = Y.map((v, i) => (v === 0 ? i : -1)).filter(i => i >= 0);

  const zerosShuffled = [...zerosIdx].sort(() => Math.random() - 0.5);
  const split = Math.floor(trainRatio * zerosShuffled.length);
  const trainIdx = [...onesIdx, ...zerosShuffled.slice(0, split)];
  const testIdx = zerosShuffled.slice(split);

  return {
    XTrain: trainIdx.map(i => X[i]),
    YTrain: trainIdx.map(i => Y[i]),
    XTest: testIdx.map(i => X[i]),
    YTest: testIdx.map(i => Y[i]),
  };
}

export function trainFixed(
  XTrain: number[][],
  YTrain: number[],
  XTest: number[][],
  YTest: number[],
  initialWeights: number[],
  lr: number,
  epochs: number,
  patience: number,
  targetAccuracy: number
):
TrainResult
{
  const XBias = insertBias(XTrain);
  const XTestBias = insertBias(XTest);
  let w = [...initialWeights];
  const trainHistory: number[] = [];
  const testHistory: number[] = [];
```

```
  let lastEpoch = epochs;

  for (let epoch = 0; epoch < epochs; epoch++) {
    const y = predict(XBias, w);
    const err = mse(y, YTrain);
    trainHistory.push(err);
    testHistory.push(mse(predict(XTestBias, w), YTest));

    if (err <= targetAccuracy) {
      lastEpoch = epoch + 1;
      break;
    }
//нет прогресса на последних patience эпохах
    if (trainHistory.length > patience) {
      const recent = trainHistory.slice(-patience);
      if (Math.max(...recent) - Math.min(...recent) < targetAccuracy) {
        lastEpoch = epoch + 1;
        break;
      }
    }

    w = delta(XBias, y, YTrain, w, lr);
  }

  return {
    trainHistory,
    testHistory,
    weights: w.slice(1),
    threshold: w[0],
    epochs: lastEpoch,
  };
}

export function trainAdaptive(
  XTrain: number[][],
  YTrain: number[],
  XTest: number[][],
  YTest: number[],
  initialWeights: number[],
  epochs: number,
  patience: number,
  targetAccuracy: number
):
TrainResult
{
  const XBias = insertBias(XTrain);
  const XTestBias = insertBias(XTest);
  let w = [...initialWeights];
  const lr = adaptiveLR(XBias);
  const trainHistory: number[] = [];
  const testHistory: number[] = [];
```

```
  let lastEpoch = epochs;

  for (let epoch = 0; epoch < epochs; epoch++) {
    const y = predict(XBias, w);
    const err = mse(y, YTrain);
    trainHistory.push(err);
    testHistory.push(mse(predict(XTestBias, w), YTest));

    if (err <= targetAccuracy) {
      lastEpoch = epoch + 1;
      break;
    }

    if (trainHistory.length > patience) {
      const recent = trainHistory.slice(-patience);
      if (Math.max(...recent) - Math.min(...recent) < targetAccuracy) {
        lastEpoch = epoch + 1;
        break;
      }
    }

    w = delta(XBias, y, YTrain, w, lr);
  }

  return {
    trainHistory,
    testHistory,
    weights: w.slice(1),
    threshold: w[0],
    epochs: lastEpoch,
  };
}

export function runInference(input: number[], weights: number[], threshold:
number): { prob: number; cls: number }
{
  const w = [threshold, ...weights];
  const x = [-1, ...input];
  const prob = sigmoid(dot(x, w));
//выбираем какой класс
  return { prob, cls: prob > 0.5 ? 1 : 0 };
}
```

фиксированный шаг

alpha	epochs	BCE_train	BCE_test	acc_train	acc_test
0.0100	3000	0.087078	0.073616	0.9978	1.0000
0.0500	3000	0.045488	0.028779	0.9978	1.0000
0.1000	3000	0.036270	0.018692	0.9978	1.0000
0.2000	3000	0.030522	0.012129	0.9978	1.0000
0.5000	3000	0.026410	0.006874	0.9978	1.0000

//ПАРАМЕТРЫ МОДЕЛИ С АЛЬФОЙ =0.5

w1 = -1.196573 w2 = -0.762958 w3 = -0.218963

w4 = -0.616754 w5 = -1.070339 w6 = -0.769751

w7 = -0.878614 w8 = -0.786729 w9 = -1.170601

Порог T = 1.840676

Точность на полной таблице: 0.998047

Количество ошибок: 1

X = [0 1 1 1 1 1 1 1 1], y_true = 1, y_pred = 0, p = 0.000299

Из таблицы видно что у нас понижается **ВСЕ ПОКА УВЕЛИЧИВАЕТСЯ** alpha. При это обучения не видно – т.к. тестовая ошибка убывает вместе с обучающей.

адаптивный шаг

Шаг вычислялся автоматически по формуле lr = 1 / mean(pow(x,2)). Динамика обучения по эпохам:

Эпоха 1 | BCE_train = 0.190909 | BCE_test = 0.187632

Эпоха 200 | BCE_train = 0.080265 | BCE_test = 0.066248

Эпоха 600 | BCE_train = 0.051106 | BCE_test = 0.034845

Эпоха 1000 | BCE_train = 0.042391 | BCE_test = 0.025417

Эпоха 2000 | BCE_train = 0.034310 | BCE_test = 0.016497

Эпоха 3000 | BCE_train = 0.031100 | BCE_test = 0.012811На графике видно монотонное и стабильное снижение без расхождения между треин и теста — признак устойчивого обобщения. Итоговые параметры модели:

w1 = -1.163917 w2 = -0.690072 w3 = -0.067433

w4 = -0.524036 w5 = -1.028808 w6 = -0.690436

w7 = -0.820707 w8 = -0.709735 w9 = -1.131078

Порог T = 1.476716

Точность на полной таблице: 0.998047

X = [0 1 1 1 1 1 1 1 1], y_true = 1, y_pred = 0, p = 0.000793

Та же одна ошибка на том же векторе, однако вероятность p=0.000793 немного выше чем у fixed-модели (0.000299), что означает чуть большую уверенность в правильном направлении.

Сравнение и общий вывод

Fixed full accuracy = 0.998047

Adaptive full accuracy = 0.998047

Fixed test BCE = 0.006874

Adaptive test BCE = 0.012811

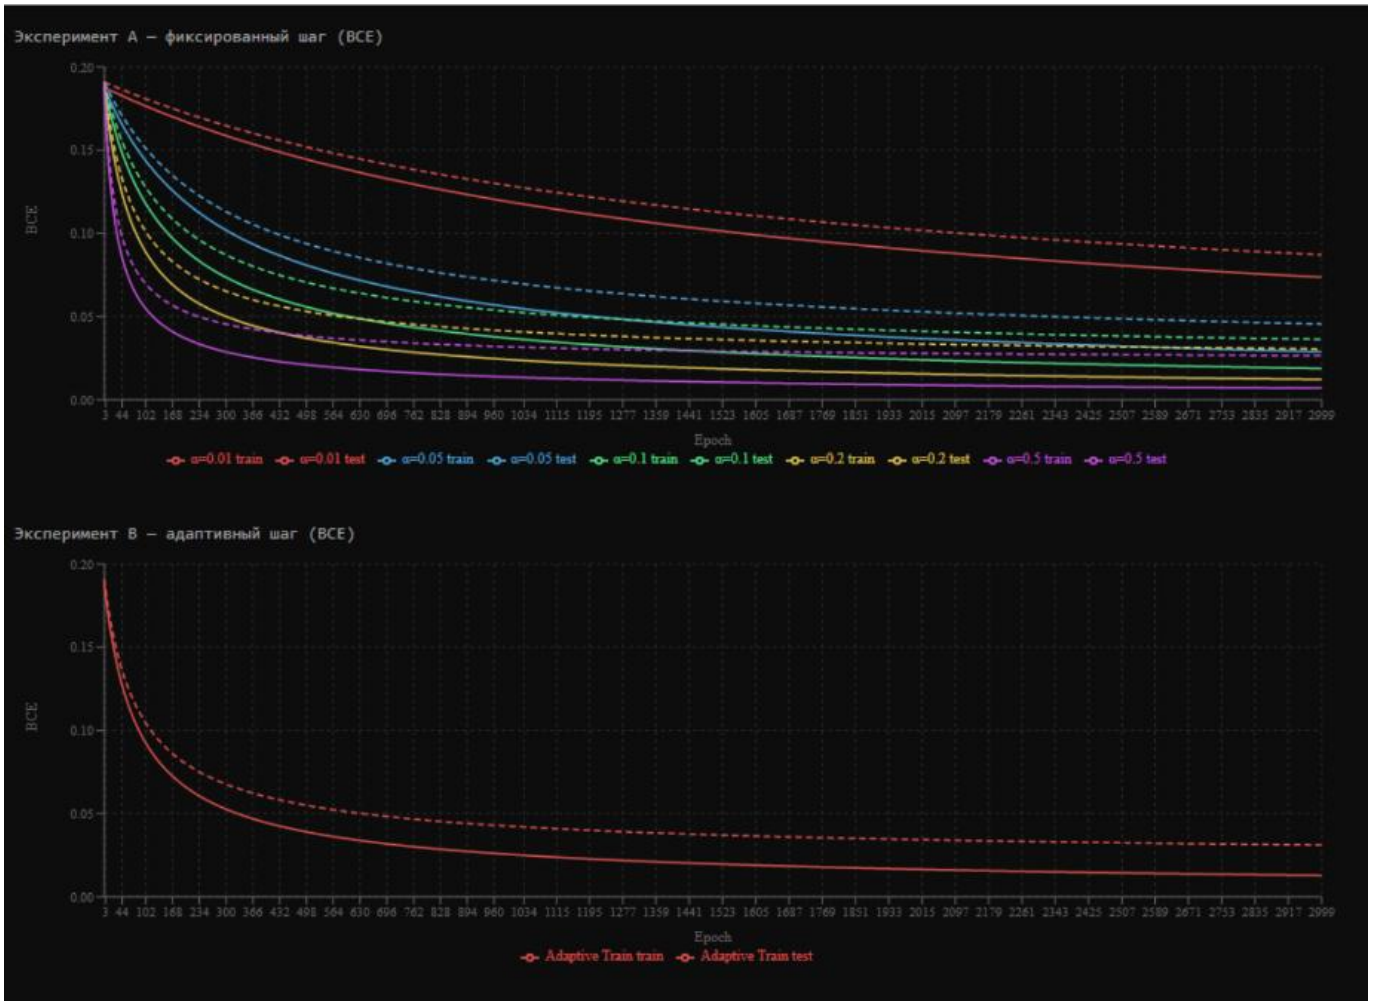

Обе модели показали одинаковую итоговую точность 0.998047. По тестовой BCE фиксированная модель с α=0.5 оказалась лучше (0.0069 против 0.0128) — она увереннее

разделяет классы на невиданных данных.

Единственная систематическая ошибка обусловлена сильным дисбалансом классов 1:511 — при 3000 эпохах обучения веса не успевают достаточно настроиться на единственный положительный пример. Адаптивный шаг обеспечивает автоматический подбор lr и стабильную сходимость без ручной настройки, однако в данном эксперименте не превзошёл оптимально подобранный фиксированный шаг по конечному качеству.

Итог – фиксированный метод лучше, так как повышается точность, однако мы вынуждены вручную перебирать альфу!