Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №1

По дисциплине «Методы решения задач в И С»

Тема: «Бинарная классификация»

Выполнил:

Студент 3 курса

Группы ИИ-26

Ковальчук А. И.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: Изучить принципы бинарной классификации и реализовать однослойную нейронную сеть (персептрон) для решения задачи классификации с использованием пороговой функции активации, а также исследовать процесс обучения модели с применением среднеквадратичной ошибки (MSE).

Постановка задачи:

1. Реализовать алгоритм обучения однослойной нейронной сети с использованием MSE в качестве функции ошибки.

2. Провести обучение сети с разными значениями шага обучения и построить график зависимости MSE от номера эпохи.

3. Выполнить визуализацию результатов классификации:

исходные точки обучающей выборки,

разделяющую линию (границу между двумя классами).

4. Реализовать режим функционирования сети:

- пользователь задаёт произвольный входной вектор,
- сеть вычисляет выходной класс,
- соответствующая точка отображается на графике,
- для корректной визуализации рекомендуется выбирать значения из диапазона ВСТАВИТЬ СВОЙ ДИАПАЗОН, например - $0.5 \leq x1, x2 \leq 1.5$Ход работы

Вариант 7

x_1	x_2	e
4	6	0
-4	6	1
4	-6	1
-4	-6	1

Код программы:

```
import numpy as np
```

```
import matplotlib.pyplot as plt



class DenseLayer:
    def __init__(self, units=1, activation='relu'):
        self.units = units
        self.activation = activation.lower()
        self.w = None
        self.b = None
        self.input = None
        self.z = None

    def forward(self, x):
        self.input = x

        if self.w is None:
            fan_in = x.shape[-1]
            if self.activation in ['relu', 'leaky_relu']:
                std = np.sqrt(2.0 / fan_in)
            else:
                std = np.sqrt(1.0 / fan_in)
            self.w = np.random.normal(0.0, std, (fan_in, self.units))
            self.b = np.zeros(self.units)

        self.z = x @ self.w + self.b
```

```
    if self.activation == 'relu':
        return np.maximum(0, self.z)
    elif self.activation == 'leaky_relu':
        return np.maximum(0.01 * self.z, self.z)
    elif self.activation == 'sigmoid':
        return 1 / (1 + np.exp(-self.z))
    elif self.activation == 'tanh':
        return np.tanh(self.z)
    elif self.activation == 'softmax':
        exp_z = np.exp(self.z - np.max(self.z, axis=1, keepdims=True))
        return exp_z / np.sum(exp_z, axis=1, keepdims=True)
    elif self.activation == 'linear':
        return self.z
    elif self.activation == 'step':
        return (self.z >= 0).astype(float)
    else:
        raise ValueError(f"Неизвестная активация: {self.activation}")

def derivative(self, a):
    if self.activation == 'relu':
        return (self.z > 0).astype(float)
    elif self.activation == 'leaky_relu':
        return (self.z > 0).astype(float) + 0.01 * (self.z <= 0).astype(float)
    elif self.activation == 'sigmoid':
```

```
            return a * (1 - a)
        elif self.activation == 'tanh':
            return 1 - a**2
        elif self.activation in ('linear', 'step'):
            return np.ones_like(a)
        elif self.activation == 'softmax':
            return np.ones_like(a)
        return np.ones_like(a)


class Input:
    def __init__(self, shape=None):
        self.shape = shape

    def forward(self, x):
        if self.shape is not None:
            expected = self.shape if isinstance(self.shape, tuple) else (self.shape,)
            if x.shape[1:] != expected:
                x = x.reshape((x.shape[0],) + expected)
        return x


class Sequential:
    def __init__(self, layers):
        self.layers = layers
```

```
    self.history_mse = []

def forward(self, x):
    out = x
    for layer in self.layers:
        out = layer.forward(out)
    return out

def fit(self, x_input, y_input, epochs=100, alpha=0.001, clip_value=5.0):
    x_input = np.asarray(x_input, dtype=np.float32)
    y_input = np.asarray(y_input, dtype=np.float32).reshape(-1, 1)

    n_samples = x_input.shape[0]
    self.history_mse = []

    for epoch in range(epochs):
        mse_sum = 0.0

        indices = np.random.permutation(n_samples)
        x_shuffled = x_input[indices]
        y_shuffled = y_input[indices]

        for i in range(n_samples):
            x = x_shuffled[i:i+1]
            y = y_shuffled[i:i+1]
```

```
activations = [x]
for layer in self.layers:
    a = layer.forward(activations[-1])
    activations.append(a)

pred = activations[-1]
mse_sum += np.mean((pred - y) ** 2)

delta = pred - y

if self.layers[-1].activation == 'step':
    delta = y - pred

for l in range(len(self.layers) - 1, -1, -1):
    layer = self.layers[l]

    if not hasattr(layer, 'activation'):
        continue

    a_prev = activations[l]

    if layer.activation == 'step':
        grad_w = a_prev.T @ delta
        grad_b = np.sum(delta, axis=0)
```

```
                else:
                    da = layer.derivative(activations[l+1])
                    delta = delta * da
                    grad_w = a_prev.T @ delta
                    grad_b = np.sum(delta, axis=0)

                grad_w = np.clip(grad_w, -clip_value, clip_value)
                grad_b = np.clip(grad_b, -clip_value, clip_value)

                layer.w += alpha * grad_w
                layer.b += alpha * grad_b

                delta = delta @ layer.w.T

        avg_mse = mse_sum / n_samples
        self.history_mse.append(avg_mse)

        if epoch % 5 == 0 or epoch == epochs - 1:
            print(f"Epoch {epoch:4d} | MSE = {avg_mse:.6f}")

def predict(self, x):
    x = np.asarray(x, dtype=np.float32)
    if x.ndim == 1:
        x = x.reshape(1, -1)
    return self.forward(x)
```

График изменения средней квадратичной ошибки:

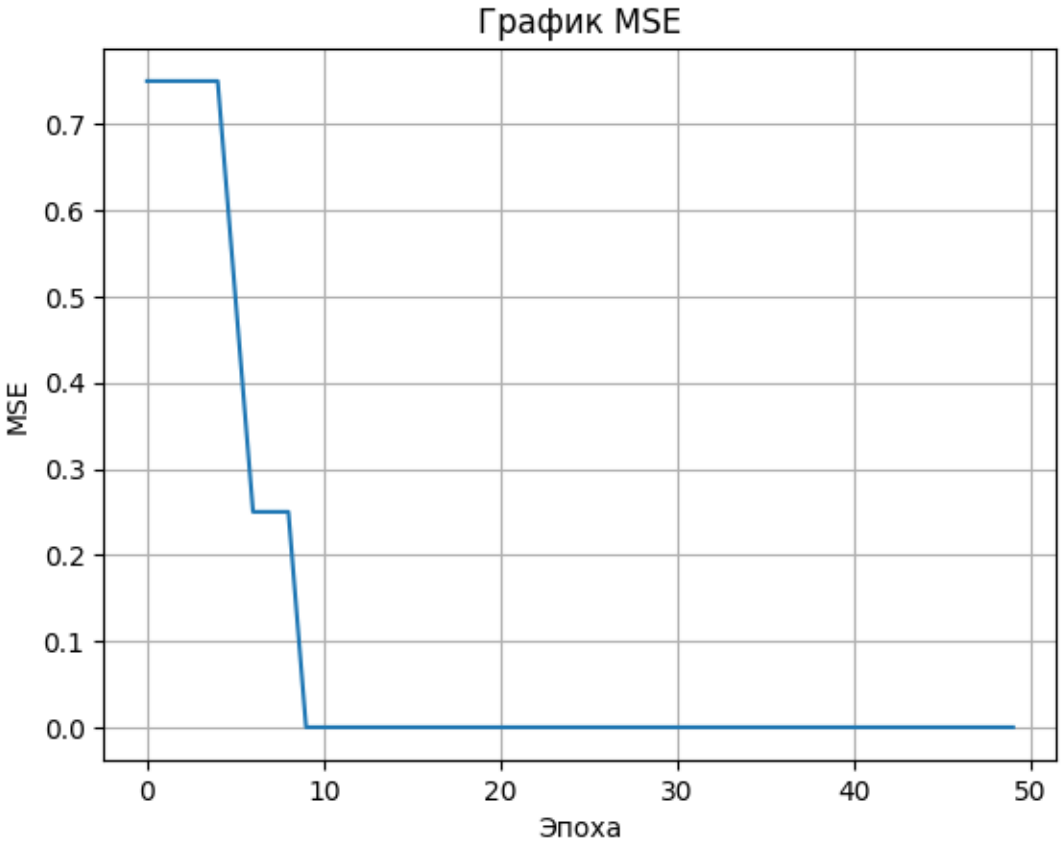

График разделяющей прямой:

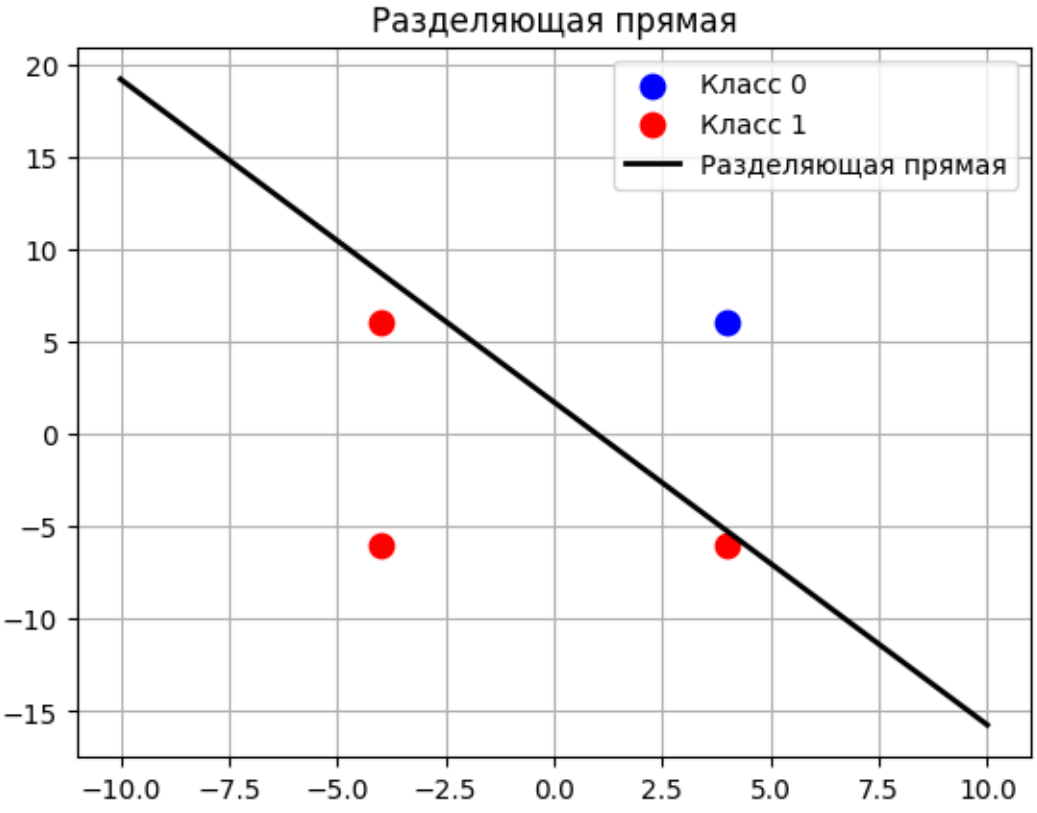

График с введёнными пользователем точками:

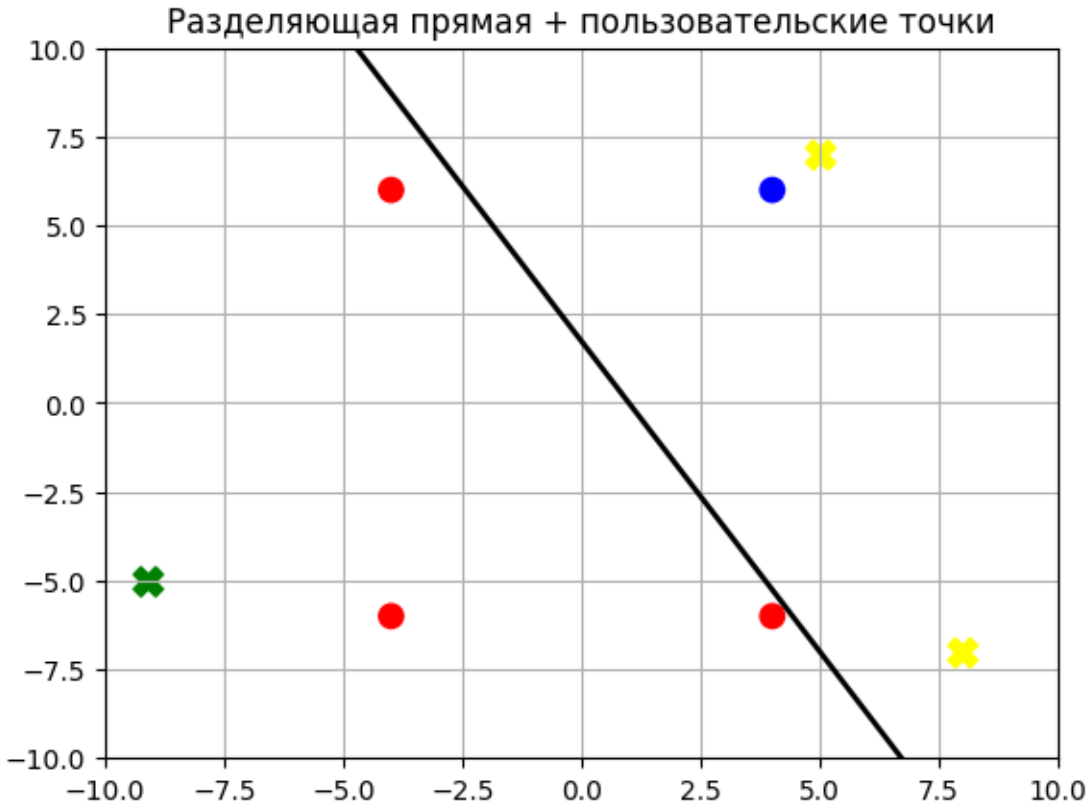

Вывод: Однослойная нейронная сеть для бинарной классификации показала, что даже минимальная архитектура способна успешно разделять данные, если корректно реализованы прямой проход, функция активации, вычисление ошибки и обратное распространение. Модель формирует линейную разделяющую границу, и качество её работы напрямую зависит от правильности градиентов, обновления весов и стабильности обучения. В ходе работы удалось добиться корректного уменьшения MSE, визуализировать процесс обучения и построить разделяющую прямую, что подтверждает работоспособность реализованного алгоритма. Такой эксперимент демонстрирует фундаментальные принципы обучения нейронных сетей и служит хорошей основой для перехода к более сложным моделям.